

Pipeline de OCR Automatizado para Extração de Gabaritos e Visualização em Tempo Real

Demonstração: Funcionalidades, Fluxos e Otimizações

24 de maio de 2026

O Objetivo: Automatizar a correção e a digitalização dos cartões-resposta dos alunos com o precisão e velocidade.

Em vez de corrigir manualmente centenas de provas, o pipeline:

- Lê imagens ou arquivos PDF.
- Identifica exatamente o exame, a escola, o professor e os alunos.
- Lê as respostas marcadas nas "bolhas" (círculos).
- Exporta dados estruturados (CSVs) prontos para análise e dashboards (Google Sheets).

Tipos de Entrada Suportados

O sistema é altamente flexível e lida com múltiplos formatos automaticamente:

Imagens (PNG, JPG)

- Fotos tiradas pelos professores ou digitalizações.
- A foto deve ser, de preferência, tirada de maneira horizontal e o mais centralizada possível.
- Processamento quase instantâneo.

Documentos (PDFs)

- Scanners com múltiplas páginas.
- O sistema extrai automaticamente as páginas de um PDF em diferentes páginas PNG e as processa.

Processamento em Lote

Você pode apontar o sistema para uma pasta contendo os PDFs e imagens misturadas, e ele processará o lote inteiro de uma só vez.

Como o Pipeline funciona, de forma rápida

- ❶ **Pré-processamento:** A imagem é convertida para tons de cinza e automaticamente endireitada para que tudo fique o mais alinhado possível.
- ❷ **Deteccção de QR Code:** O sistema escaneia o topo da página buscando um QR Code.
- ❸ **Extração da Grade:** Encontramos as linhas verticais e horizontais da tabela de respostas para isolar cada bolha individualmente.
- ❹ **Análise das Bolhas:** O sistema analisa as bolhas isoladas (análise de densidade de pixels) para determinar qual opção o aluno marcou.
- ❺ **Exportação:** Os resultados são compilados em uma planilha mestre.

Informações retiradas

- O ID do Professor, o ID da Escola e a Turma/Bimestre.
- Quais questões exatas estão na página e sua ordem.
- Quais alunos estão nesta página específica (IDs dos Alunos).

Como as "bolhas" são detectadas

O método proposto:

- **Isolamento:** Recortamos o quadrado aproximado onde a bolha está.
- **Limiarização:** Filtramos a cor de fundo do papel.
- **Checagem de Densidade:** Contamos quantos "pixels escuros" existem dentro da bolha em comparação com uma vazia.
- **Pontuação de Confiança:** Se a densidade for alta (acima de um limiar), temos 100% de certeza de que foi preenchida.

Otimizando para Velocidade

Implementei, visando otimizar performance, sem perder a acurácia:

- ① Operações com bibliotecas otimizadas (OpenCV e Numpy).
- ② Rejeição de modelos de IA Generativa.
- ③ Processamento Paralelo Multi-core (Multiprocessing).

Como Executar: Comandos do Terminal

O sistema é controlado através de uma Interface de Linha de Comando (CLI) simples.

Processar uma Única Imagem ou PDF

```
poetry run python main.py --image "exemplos/prova.pdf"
```

Processar um Diretório/Lote Completo (com Multiprocessamento)

```
poetry run python main.py --batch "exemplos/"
```


Com todas as otimizações ativas, eis o que o sistema alcança hoje:

- **Tempo Puro de Extração: 0.18 segundos** por página.
- **Velocidade Real em Lote:** Graças ao multiprocessamento, o tempo de espera cai para cerca de **0.05 segundos** por página.

Transparência e Controle do Processo

- **Imagens de Depuração (Debug):** O pipeline pode gerar imagens intermediárias mostrando exatamente onde encontrou o QR Code, a grade da tabela e as caixas delimitadoras de cada "bolha" processada.
- **Antes e Depois:** As imagens permitem visualizar a imagem original (torta ou com sombras) e a versão processada após a correção de perspectiva.
- **Tratamento de Exceções:** Se uma página estiver muito rasgada ou o QR Code for ilegível, o sistema não para. Ele gera um log de erro e separa o arquivo problemático para revisão manual, garantindo que nenhum aluno fique sem nota.

Dados Estruturados e Prontos para Uso

O sistema não entrega apenas notas cruas, mas sim uma visão granular de cada resposta, gerando arquivos CSV. Exemplo de saída:

ID Aluno	Q1	Q2	Q3	Q47	Q5	Q6-A	Q6-B
A3859	B	1	2	3	2	B	2
A3860	B	2	B	1	2	2	1
A3861	B	1	2	1	B	2	B

- **Matrizes de Confiança:** Além da resposta, o pipeline gera arquivos paralelos informando a densidade de preenchimento e o grau de confiança (0-100%) para cada bolha lida, alertando para possíveis rasuras.

Objetivos Atingidos Os objetivos combinados foram cumpridos. O processamento terá que ser monitorado, para ajuste de parâmetros, mas a implementação está fechada em um ciclo End-to-End (do começo ao fim).